

ANÁLISE DE DADOS



Desafio Técnico

Speed Hiring
1ra edição



Autores:

**John Jairo Cardona | Maoly Lara
Nativeth Duno | Silvia Ruiz**



Brasil
2023

Junho / 2023

O Instituto Brasileiro de Pesquisa (**IBP**), é uma empresa fictícia criada com fins educativos, para dar personalidade a uma análise de dados, como requerimento do challenge, da 1ra edição do speed Hiring - 2023, da Toti Diversidade. Projeto que tem como visão a empregabilidade de migrantes na área de dados e desenvolvimento web da Toti, em parceria com OIM — ONU Migração, USAID — Do povo dos Estados Unidos, e o Projeto Oportunidades — Integração no Brasil.

John Jairo Cardona Hernández | [Analista de dados](#)

Maoly de los Angeles Lara Serrano | [Desenvolvedor Full Stack](#)

Nadiveth Elena Duno Escalona | [Cientista de dados](#)

Silvia José Ruiz Bustamante | [Analista de dados](#)

RESUMO

O relatório apresenta as análises de dados, a partir de dados simulados de 5 anos de pesquisa científica, do Instituto Brasileiro de Pesquisa (IBP).

Se iniciou criando um modelo de entidade relacionamento normalizado e se modelou a base de dados com **MySQL**.

Posteriormente, continuamos com a simulação dos dados, os quais foram criados em Colab com a linguagem de programação **Python**, fazendo uso, da **Inteligência Artificial** da OpenAi, com a integração da biblioteca do **Chat GPT**, para trazer dados adaptados à realidade, e garantido boas práticas na otimização do tempo e recursos.

Tudo isso com a finalidade de criar dashboards estratégicos, baseados em premissas reais de negócios, análogas aos institutos de pesquisa científicos brasileiros; para criar os dashboards se usou **Power BI**.

SUMÁRIO

1. O problema
2. Proposta de solução dos especialistas de Dados — Storytelling.
3. Metodologia Ágil
4. Modelo de entidade relacionamento (**MER**)
5. Modelagem de dados com **MySQL**
6. Simulação de dados em **Python** — Integração da Inteligência Artificial
7. Dashboard e Relatórios em Power BI

Home

Dashboard geral

Projetos

Cientistas

Financiamento

8. Análise de dados

Dashboard geral

Gráfico 01: Distribuição de Projetos por Ano

Gráfico 02: Projetos por Região

Gráfico 03: Tipo de Financiamento por Região

Gráfico 04: Distribuição de Projetos por Cidades

Projetos

Gráfico 05: Distribuição de Projetos por Área

Gráfico 06: Distribuição de Projetos por Ano

Gráfico 07: Distribuição de Projetos por Região

Gráfico 08: Nuvem de palavras em relação à frequência da área nos projetos

Cientistas

Gráfico 09: Relação de Cientistas adscritos ao Instituto

Gráfico 10: Relação de Cientistas por horas de Pesquisa

Financiamento

Gráfico 11: Gráfico 11: Investimento por ano

Gráfico 12: Verba não utilizada por ano

Gráfico 13: Custos dos Projetos por Regiões

Extras

Fluxo de projeto

Autores


Repositório do GitHub

Página web do projeto

1. O problema

Desenvolver um dashboard em Power BI sobre o estado atual da empresa científica, **Instituto Brasileiro de Pesquisa (IBP)**, tendo como ponto de partida o modelo relacionamento disponível em:

https://en.wikibooks.org/wiki/SQL_Exercises/Scientists



O Instituto Brasileiro de Pesquisa — IBP é uma empresa fictícia dedicada ao desenvolvimento de projetos científicos, nas principais áreas globais (Tecnologia, Sociologia, Políticas Públicas, etc.). A principal dificuldade do instituto é a organização, controle e interpretação dos dados que geram.

2. Proposta de solução dos especialistas de Dados — Storytelling

A partir do problema, propomos as seguintes soluções que irão ajudar ao IBP a maximizar a eficiência na manipulação de seus dados:

1. Reestruturar o banco de dados.

2. Implementar um banco de dados em **MySQL**, bem estruturado e modelado, com a inclusão de novas entidades ou tabelas que permitirão a integridade e maior armazenamento dos dados.

Para nutrir as entidades da base de dados, os dados serão simulados em Colab com a linguagem de programação **Python**, fazendo uso da **Inteligência Artificial**.

Com isso, a empresa terá acesso rápido e fácil a todas as informações relevantes do projeto e cientistas envolvidos. Controle dos estados financeiros, produtivos e logísticos da execução dos projetos.

3. Criar dashboard ou relatórios em **Power BI** para a tomada de decisões assertivas e estratégicas.
4. Analisar os dados acumulados, que auxiliem na tomada de decisões com um olhar holístico baseado em regras de negócios dos principais institutos de pesquisa científica do Brasil.

As propostas aqui formuladas, têm a finalidade de automatizar os processos do **IBP** e melhorar as experiências futuras, na tomada de decisões assertivas e estratégicas a partir dos dados; que possam construir políticas internas em prol do desenvolvimento do instituto e permitam que os cientistas se concentrem no que realmente importa: a pesquisa.

Por conseguinte, o IBP poderá aumentar sua eficiência e produtividade, reduzir erros e atrasos, e tomar decisões mais estratégicas e assertivas. Isso permitirá que o IBP continue a se destacar como uma das principais instituições de pesquisa do país, gerando impactos significativos na sociedade e contribuindo para o avanço da ciência, tecnologia e inovação.

3. Metodologia Ágil



Foi realizada uma análise dos dados disponibilizados pelo **IBP**, que se dedica ao desenvolvimento de pesquisas com uso de ciência, tecnologia e inovação, onde aplicamos a metodologia ágil Kanban para otimizar o processo de trabalho. Começamos dividindo o projeto em sprints, onde definimos objetivos específicos que queríamos atingir em um determinado período e captados no Trello para gerenciamento do projeto e as tarefas foram divididas, baseada na especialidade de nossa equipe.

As daily meeting, se efetuaram pelo canal Google Meet todos às 21 horas, para compartilhar avanços dos sprints, possíveis obstáculos, buscar soluções colaborativas, discutir ideias e tomar decisões em conjunto. Essas reuniões permitiram manter uma comunicação assertiva entre os membros da equipe e garantir que todos estivessem cientes do andamento das tarefas e das dificuldades. Além disso, nos deu a oportunidade de fazer mudanças rápidas no planejamento e na utilização de recursos conforme o necessário.

Durante o processo foi utilizado a ferramenta Trello como hospedagem e controle dos sprints.

Principais sprints:

- ☐ Personificação do cliente.
- ☐ Criação de uma identidade visual.
- ☐ Criação de um modelo de entidade relacional.
- ☐ Normalização da base de dados.
- ☐ Simulação dos dados, para nutrir a base de dados.
- ☐ Criação de arquivos CSV com os dados.
- ☐ Criação de dashboards.
- ☐ Elaboração de insights e conclusões.




Disponível em: <https://bit.ly/3ounIPz>

4. Modelo de entidade relacionamento (MER)

Para modelar os dados, se estudaram as principais entidades citadas no problema do Instituto Brasileiro de Pesquisa (IBP), as quais eram Cientistas e Projetos é uma entidade que guardava os históricos e relações entre os projetos e cientistas. A partir delas se construíram novas entidades, guardando a integridade das 3 principais normas internacionais dos processos em normalização de base de dados.


Tendo assim um modelo de dados robusto e íntegro, onde os dados conservam sua integridade e a não redundância.

Iniciamos com um banco de dados com 3 entidades, duas principais e uma ponte que relaciona as chaves primárias das principais.



Baseados em regras de negócio e estudos de mercado, para a automatização de dados de um instituto científico, se incorporou entidades como a que cidade e região de Brasil está adstrito ao projeto, qual é a área de pesquisa deste projeto, o tipo de financiamento. E para os cientistas, o sexo, chave para identificar e fazer análises descritivos em relação a eles.

Agora temos um banco de dados mais robusto e normalizado, aqui a proposta.




Disponível em: <https://bit.ly/3WqKsar>


5. Modelagem de dados com MySQL

Usando o modelo MER da seção anterior, se criaram os scripts em SQL para a criação do banco de dados, listamos aqui os mais importantes:


Inserindo dados na tabela Sexo




Inserindo dados na tabela Cientistas




Inserindo dados na tabela Região



Inserindo dados na tabela Área



Inserindo dados na tabela Projetos



Consulta (query) na tabela Projetos

The screenshot shows the MySQL Workbench interface. In the left sidebar, the 'SCHEMAS' panel is open, showing the 'ibp' database with a tree of tables including 'area', 'atribuicao', 'cientistas', 'financiamento', 'projetos', and 'regiao'. The 'projetos' table is selected. In the central query editor, the following SQL query is entered:

```
1 • SELECT * FROM ibp.projetos;
```

Below the query editor, the 'Result Grid' displays the data from the 'projetos' table. The table has 10 columns: code_projeto, titulo, area, horas, data_inicio, data_fim, code_financiamento, custo, and code_regiao. The data is as follows:

code_projeto	titulo	area	horas	data_inicio	data_fim	code_financiamento	custo	code_regiao
Aaaa4244	A análise do comport...	Engenharia ...	514	2018-09-25	2019-02-22	A	69860	1
Aaaa4721	Análise da relação e...	Saúde Mental	566	2018-11-30	2019-02-08	A	93408	5
AaC162	Análise da relação e...	Saúde	428	2021-12-06	2022-03-17	A	85152	4
AaC2829	Análise da poluição ...	Meio Ambiente	1407	2019-09-15	2020-01-11	A	54908	2
Aacc251	Análise do impacto s...	Economia	339	2021-03-30	2021-05-30	A	50649	1
Aaee682	Aplicação de técnica...	Tecnologia	811	2019-11-11	2019-12-30	A	68470	5
AaF2299	Análise de comporta...	Biologia	1086	2021-08-10	2021-09-10	A	98968	5
Aaff1561	Análise de práticas d...	Educação	930	2021-06-07	2021-11-19	A	59385	3
Aaff1733	Ação contra a muda...	Mudança Cli...	1292	2020-07-25	2020-09-05	A	68791	1
Aaff3976	Análise da eficácia d...	Nutrição	688	2019-09-17	2019-11-16	A	62969	5

Geral do banco de dados

The screenshot shows the MySQL Workbench interface with the 'script_sql_projetosIBP' script open. The script contains the following SQL commands:

```
1 -- MySQL Script generated by MySQL workbench
2 -- Mon May 15 23:01:10 2023
3 -- Model: New Model    Version: 1.0
4 -- MySQL Workbench Forward Engineering
5
6 • SET @OLD_UNIQUE_CHECKS=@@UNIQUE_CHECKS, UNIQUE_CHECKS=0;
7 • SET @OLD_FOREIGN_KEY_CHECKS=@@FOREIGN_KEY_CHECKS, FOREIGN_KEY_CHECKS=0;
8 • SET @OLD_SQL_MODE=@@SQL_MODE, SQL_MODE='ONLY_FULL_GROUP_BY,STRICT_TRANS_TABLES,NO_ZERO_IN_DATE,NO_ZERO_DATE,ERROR_FOR_DIVISION_BY_ZERO,NO_ENGINE_SUBSTITUTION';
9
10
11 -- Schema ibp
12
13
14
15 -- Schema ibp
16
17 • CREATE SCHEMA IF NOT EXISTS `ibp` DEFAULT CHARACTER SET utf8 ;
18 • USE `ibp` ;
19
20
21 -- Table `ibp`.`area`
```

6. Simulação de dados em Python — Integração da Inteligência Artificial

Os dados incluídos no banco de dados, foram simulados, os quais foram criados em Colab com a linguagem de programação **Python**, fazendo uso, da **Inteligência Artificial** da OpenAi, com a integração da biblioteca do **ChatGPT**, para trazer dados adaptados à realidade, e garantido boas práticas na otimização do tempo e recursos.

Um código feito em Open Source, disponível para a comunidade de desenvolvedores no mundo todo, o qual segue aberto para possíveis aportes e sugestões.

 Open in Colab

SpeedHiring - Challenge 2023



John Jairo Cardona | Analista de dados

Maoly Lara | Desenvolvedor Full Stack

Nadi Duno | Cientista de dados

Silvia Ruiz | Analista de dados

Embaixadores da Toti Diversidade

API do ChatGpt da (OpenAI) 

Instalando pacote com o "Pip Installs Packages"

```
In [ ]: pip install openai

Looking in indexes: https://pypi.org/simple, https://us-python.pkg.dev/colab-wheels/public/simple/
Requirement already satisfied: openai in /usr/local/lib/python3.10/dist-packages (0.27.6)
Requirement already satisfied: requests>=2.20 in /usr/local/lib/python3.10/dist-packages (from openai) (2.27.1)
Requirement already satisfied: tqdm in /usr/local/lib/python3.10/dist-packages (from openai) (4.65.0)
Requirement already satisfied: aiohttp in /usr/local/lib/python3.10/dist-packages (from openai) (3.8.4)
Requirement already satisfied: urllib3<1.27,>=1.21.1 in /usr/local/lib/python3.10/dist-packages (from requests>=2.20->openai)
/1 26 143
```

```
Importando Bibliotecas

In [ ]: from typing_extensions import ContextManager
import openai, os

Gerar a API_Key em https://platform.openai.com/account/api-keys

In [ ]: # Configura a chave de API da OpenAI usando a variável de ambiente 'OPENAI_API_KEY'
os.environ['OPENAI_API_KEY'] = 'escreveraquisenhadaAPIKey'

In [ ]: #Escreve uma solicitação para o Chat GPT e ele regressa a informação em Data Frame (Deve estar especificado no texto)
transcription="Cria 30 linhas, em aspas duplas e separado por vírgula, duas informações, a primeira são títulos de projeto.
# Configura a chave de API da OpenAI usando a variável de ambiente 'OPENAI_API_KEY'
openai.api_key = os.environ.get('OPENAI_API_KEY')
response = openai.ChatCompletion.create(
    model="gpt-3.5-turbo",
    messages=[ { "role": "user", "content": transcription } ]
)
chatgpt_response = response.choices[0].message.content
print(chatgpt_response)

In [ ]: import pandas as pd

In [ ]: df1 = pd.DataFrame({
    'Titulo': ['Estudo da biodiversidade marinha em áreas de recifes de coral', 'Mapeamento da cobertura vegetal da Amazônia',
    'Área': ['Biologia Marinha', 'Ecologia', 'Climatologia', 'Saúde Pública', 'Engenharia de Materiais', 'Energias Renováveis']
})
df1

Out[ ]:
```

	Titulo	Area
0	Estudo da biodiversidade marinha em áreas de r...	Biologia Marinha
1	Mapeamento da cobertura vegetal da Amazônia	Ecologia
2	Análise das mudanças climáticas na Antártica	Climatologia
3	Impacto da poluição atmosférica na saúde humana	Saúde Pública
4	Desenvolvimento de materiais alternativos para...	Engenharia de Materiais
5	Estudo do potencial energético da biomassa na ...	Energias Renováveis
6	Análise de dados climáticos para melhorar o pl...	Ciência de Dados
7	Desenvolvimento de novas tecnologias para a tr...	Geologia

Código disponível no Github em: <https://bit.ly/42Y4OKu>

Obtidos estes dados pela inteligência artificial, se procedeu a implementar a Ciência de Dados, para tratá-los, tirar lixo, separar colunas, eliminar aspas e tirar espaços em brancos ao começo do texto, por mencionar algumas tarefas efetuadas.

Ciência de Dados

Para tratar os dados, tirar lixo, separar colunas, eliminar aspas, tirar espaços em branco no começo do texto, etc

Primer DataFrame

```
In [ ]: projetos
```

```
Out [ ]:      Título do Projeto, Área de Pesquisa
0  "Estudo sobre o impacto das mudanças climática...
1  "Análise da eficácia de novos tratamentos para...
2  "Desenvolvimento de tecnologias sustentáveis p...
3  "Estudo sobre a influência da urbanização na q...
4  "Análise do impacto socioeconômico de política...
...
882 "Garantia de acesso à educação de qualidade pa...
883 "Desenvolvimento de programas para a prevenção...
884 "Inclusão de crianças com deficiência na escol...
885 "Desenvolvimento de políticas públicas para a ...
886 "Redução das desigualdades sociais entre crian...
```

887 rows × 1 columns

Eliminando as aspas duplas

```
In [ ]: projetos = projetos.replace('\"', '', regex=True)
projetos
```

Separando em columns os dados, Título e Área

```
In [ ]: projetos.rename(columns={'Título do Projeto, Área de Pesquisa': 'titulo'}, inplace=True)
#print(projetos.columns)
projetos=projetos['titulo'].str.split(',',expand=True)
#projetosnew[['titulo', 'area', 'none']] = projetos['titulo'].str.split(',',expand=True)
projetos
```

```
In [ ]: #Remplazando os nome da coluna
projetos.rename(columns={0: 'Titulo',1: 'Area',2: 'Vazio'}, inplace=True)
projetos
```

```
In [ ]: #Eliminando uma coluna vazia
projetos.drop('Vazio', axis=1, inplace=True)
projetos
```

Out[]:

	Titulo	Area
0	Estudo sobre o impacto das mudanças climáticas...	Meio Ambiente
1	Análise da eficácia de novos tratamentos para ...	Saúde
2	Desenvolvimento de tecnologias sustentáveis pa...	Agricultura
3	Estudo sobre a influência da urbanização na qu...	Urbanização
4	Análise do impacto socioeconômico de políticas...	Economia
...	...	...
882	Garantia de acesso à educação de qualidade par...	Educação
883	Desenvolvimento de programas para a prevenção ...	Políticas Públicas
884	Inclusão de crianças com deficiência na escola...	Inclusão
885	Desenvolvimento de políticas públicas para a p...	Políticas Públicas
886	Redução das desigualdades sociais entre crianç...	Políticas Públicas

887 rows × 2 columns

Depois se continuou a completar as tabelas de projeto, com códigos numéricos consecutivos, códigos alfanuméricos aleatórios e descrições reais das regiões e cidades do Brasil.

Aqui alguns casos pontuais:

☐ Código do projeto no formato AeHh1:

A	e	Hh	1
A	(Tipo de Financiamento A, B ou C)		
e	(Primiero letra do título do projeto)		
Hh	Tipo da pesquisa A-Z-AA-ZZ		
1	Número aleatório 1-3.000		

☐ Código do financiamento:

Para o Financiamento se consideraram 3 métricas ou categorias: A, B e C. Onde A(Alto) B(Médio) e C(Baixo):

- Categoria A: para projetos de alto financiamento, que envolvem pesquisa de ponta, colaboração internacional e impacto social. O valor médio dessa categoria é de R\$50.000.00 até R\$100.000. Exemplos de projetos dessa categoria são: desenvolvimento de vacinas, estudos sobre mudanças climáticas, inovação tecnológica, etc.
- Categoria B: para projetos de médio financiamento, que envolvem pesquisa aplicada, desenvolvimento local e relevância científica. O valor médio dessa categoria é de R\$10.000 até R\$50.000. Exemplos de projetos dessa categoria são: melhoria da qualidade da educação, preservação da biodiversidade, promoção da saúde pública, etc.
- Categoria C: para projetos de baixo financiamento, que envolvem pesquisa básica, formação de recursos humanos e divulgação científica. O valor médio dessa categoria é de R\$1.000 a R\$10.000. Exemplos de projetos dessa categoria são: estudos sobre a história e a cultura do Brasil.

Logrando assim uma tabela, com dados adaptados à realidade.

Out[]:	CodeN	Titulo	Area	Horas	DataInicio	DataFim	code_fina	costo	code_regi	regiao
0	Beyy634	Estudo sobre o impacto das mudanças climáticas...	Meio Ambiente	390	20/7/2019	2/11/2019	B	21893	2	Nordeste

Aqui a tabela final dos projetos com 887 registros:

Out[]:	CodeN	Titulo	Area	Horas	DataInicio	DataFim	code_fina	costo	code_regi	regiao
0	Beyy634	Estudo sobre o impacto das mudanças climáticas...	Meio Ambiente	390	20/7/2019	2/11/2019	B	21893	2	Nordeste
1	BaT2552	Análise da eficácia de novos tratamentos para ...	Saúde	572	27/8/2020	17/9/2020	B	44973	5	Sul
2	Adaa3991	Desenvolvimento de tecnologias sustentáveis pa...	Agricultura	1063	6/4/2021	26/9/2021	A	77942	2	Nordeste
3	CeT2796	Estudo sobre a influência da urbanização na qu...	Urbanização	1422	2/9/2022	18/10/2022	C	7946	5	Sul
4	Aacc251	Análise do impacto socioeconômico de políticas...	Economia	339	30/3/2021	30/5/2021	A	50649	1	Centro-Oeste
...	...	...	...	...	...	...	...	...	...	...
241	CtR3711	Tecnologias avançadas para monitoramento ambie...	Meio ambiente	1397	20/4/2021	16/6/2021	C	8741	5	Sul
243	AdY4108	Desenvolvimento de novos materiais para constr...	Engenharia civil	948	8/3/2019	19/8/2019	A	57405	1	Centro-Oeste
245	AaQ514	Análise de dados para prevenção de epidemias e...	Epidemiologia	1335	8/1/2022	13/3/2022	A	62461	3	Norte
249	Cmdd720	Monitoramento do derretimento de geleiras e im...	Meio ambiente	1399	18/1/2020	28/6/2020	C	9007	1	Centro-Oeste
261	Bmyy3039	Monitoramento de florestas tropicais e desenvo...	Meio ambiente	464	14/2/2020	17/5/2020	B	26639	3	Norte

887 rows × 10 columns

Para a tabela cientista se usou uma biblioteca chamada Faker para gerar nomes aleatórios e CPF baseados na região do Brasil.

Cientistas

Gerando CPF aleatorios

```
In [ ]: from faker import Faker
fake = Faker('pt_BR')
```

```
In [ ]: def cpfcientista():
    cpf = fake.cpf()
    return cpf
```

Gerando Nomes aleatorios

```
In [ ]: from gender_guesser.detector import Detector
detector = Detector()

def sexocientista(nome):
    genero = detector.get_gender(nome)
    if genero == 'female':
        return (1, 'Feminino')
    elif genero == 'male':
        return (2, 'Masculino')
    else:
        return (3, 'Não definido')
```

Os dados foram validados para evitar duplicidade nos CPF.

```
Verificar não ter CPF ou SSN duplicadod

In [ ]: duplicados2=cientistanovo['CPF'].value_counts()
        duplicados2

Out[ ]: 451.706.923-07    1
        768.043.129-96    1
        598.406.312-33    1
        653.084.912-24    1
        940.261.537-70    1
        ..
        273.409.518-14    1
        764.310.259-70    1
        536.814.927-19    1
        859.731.062-68    1
        182.645.079-30    1
        Name: CPF, Length: 200, dtype: int64
```

Out[]:

	CPF	nome	code_sexo	sexo
2	546.301.879-01	Miguel Cardoso	2	Masculino
3	270.691.548-01	Rafael Souza	2	Masculino
4	935.741.260-34	Danilo Campos	2	Masculino
5	126.390.758-02	Carolina Pinto	1	Feminino
6	630.142.958-33	Larissa Vieira	1	Feminino
...	...	...	...	...
192	247.016.983-69	Augusto Monteiro	2	Masculino
193	492.601.587-02	Miguel da Cunha	2	Masculino
194	643.071.852-26	Enrico Correia	2	Masculino
198	920.164.738-78	Danilo Lopes	2	Masculino
199	182.645.079-30	Larissa Moraes	1	Feminino

127 rows × 4 columns

Se geraram estatísticas e se exportam os arquivos em CSV.

Estadísticas

```
In [ ]: #projetostabela.describe(include='all')
```

```
In [ ]: #cientistastabela.describe(include='all')
```

```
In [ ]: #atributotabela.describe(include='all')
```


Exportando Dados

```
In [ ]: #projetostabela.to_csv('tabelaprojetos.csv')
```

```
In [ ]: cientistastabela.to_csv('cientistas.csv')
```

```
In [ ]: atributotabela.to_csv('atributo.csv')
```

Código disponível no Github em: <https://bit.ly/45g3OTP>




CVS disponível no Github em: <https://bit.ly/3od1jB2>


7. Dashboard e Relatórios em Power BI

Os dados no formato CSV se unificam em uma única planilha e se carregam no Power BI desktop.

Para iniciar a criar os visuais no Power BI, trabalhamos com uma paleta de cores, selecionada em Adobe Color.



Para cada região do Brasil associamos uma cor, dessa paleta, para ter concordância entre dados e cores; gerando assim visuais mais profissionais.




A continuação se apresentam os dashboards produzidos:


Home




Dashboard geral




Projetos



Cientistas



O arquivo se sobe na nuvem para poder compartilhar com a comunidade, tendo as duas versões, a local e a remota.




Dashboard versão web disponível em: <https://bit.ly/3Mrmpnj>

8. Análise de dados


Dashboard geral

Gráfico 01: Distribuição de Projetos por Ano




Podemos observar uma variação no número de projetos ao longo dos anos analisados. Em 2018 foram inscritos 179 projetos, seguindo-se um ligeiro decréscimo em 2019 com 167 projetos. No entanto, em 2020, houve um aumento no número de projetos para 188, indicando um crescimento significativo. Em 2021, o número diminuiu ligeiramente para 177 projetos e, em 2022, ficou praticamente estável em 176 projetos. Essa tendência pode sugerir uma estabilização no número de projetos após um período de crescimento.


Gráfico 02: Projetos por Região



A análise do gráfico revela a distribuição percentual dos projetos realizados nas diferentes regiões do Brasil. Observa-se que a região Sudeste possui o maior percentual, com 36,19% dos projetos, indicando uma significativa concentração de atividades científicas nesta área. A região Sul segue em segundo lugar com 26,61% dos projetos, a região Nordeste também apresenta uma proporção considerável representando 24,35%, seguida do Centro-Oeste com 10,03%. Por outro lado, a região Norte tem a menor proporção de projetos, com apenas 2,82%. Esses resultados indicam uma distribuição desigual de projetos nas diferentes regiões, o que pode refletir disparidades em termos de desenvolvimento científico, recursos e oportunidades de pesquisa no país.

Gráfico 03: Tipo de Financiamento por Região






O gráfico mostra a quantidade de projetos de acordo com os tipos de projetos, e observa-se que o tipo “Tecnologia” possui o maior número de projetos, seguido de “Inclusão”, “Biologia” e “Políticas Públicas”. Esta análise revela a distribuição dos projetos entre as diferentes áreas temáticas.

O tipo de projeto "Inclusão" mostra uma atenção destacada à equidade e inclusão social.

O tipo "Biologia" sugere um foco em projetos relacionados às ciências biológicas, como pesquisa em biotecnologia, genética, ecologia ou medicina.

Por fim, o tipo "Políticas Públicas" indica projetos voltados para a esfera governamental e políticas sociais.

Gráfico 06: Distribuição de Projetos por Ano



Podemos observar uma variação no número de projetos ao longo dos anos analisados. Em 2018 foram inscritos 179 projetos, seguindo-se um ligeiro decréscimo em 2019 com 167 projetos. No entanto, em 2020, houve um aumento no número de projetos para 188, indicando um crescimento significativo. Em 2021, o número diminuiu ligeiramente para 177 projetos e, em 2022, ficou praticamente estável em 176 projetos. Essa tendência pode sugerir uma estabilização no número de projetos após um período de crescimento.

Gráfico 07: Distribuição de Projetos por Região





Gráfico 08: Nuvem de palavras em relação à frequência da área nos projetos



Cientistas

Gráfico 09: Relação de Cientistas adscritos ao Instituto



Contemplamos a distribuição de gênero dos cientistas que trabalham em um instituto, onde os homens 42,52% e as mulheres representam 57,48%. Esse resultado indica haver uma presença significativa de mulheres no instituto, superando ligeiramente a proporção de homens. Esta representação de maior presença de mulheres no campo científico é um resultado animador, já que historicamente houve uma sub-representação de mulheres neste campo.


Gráfico 10: Relação de Cientistas por horas de Pesquisa



O gráfico mostra a relação entre os cientistas e as horas trabalhadas, onde se pode observar que as mulheres representam 32,64% e os homens 67,36%. Isso sugere uma discrepância em termos de distribuição de gênero e tempo gasto no trabalho científico. Isso pode indicar a existência de desigualdades de gênero em termos de carga de trabalho ou oportunidades de trabalho disponíveis para as mulheres no campo científico.

Financiamento

Gráfico 11: Investimento por ano



O gráfico mostra-nos a quantidade de investimento em projetos ao longo de cinco anos onde se revela uma tendência geral de variação dos valores de investimento. Em 2018, o investimento foi de 5 milhões, seguido de um aumento em 2019 para 6,8 milhões. Em 2020, houve uma ligeira queda para 6,2 milhões de unidades monetárias, seguida de uma nova redução em 2021 para 5,7 milhões. No entanto, em 2022, o investimento voltou a recuperar para 6,8 milhões. A previsão para o ano seguinte é de 6,3 milhões. Refira-se que temos uma verba anual de 7 milhões, o que indica alguma estabilidade na quantidade de investimento.

Gráfico 12: Verba não utilizada por ano



O IBP tem uma verba anual de R\$7.000.000 a qual é distribuída nas licitações dos cientistas ao longo dos anos. Desde o 2018 até o 2022 o IBP vem recebendo a mesma quantia como aporte financeiro.

Neste período o **IBP** a utilizado um total de R\$32.155.986 da verba entregue.

Ano	Nº Proj.	Custos	% Utiliza...	% Não Ut...
2018	179	R\$ 6.788.334,00	96,98%	3,02%
2019	167	R\$ 6.090.232,00	87,00%	13,00%
2020	188	R\$ 6.461.202,00	92,30%	7,70%
2021	177	R\$ 5.900.260,00	84,29%	15,71%
2022	176	R\$ 6.915.958,00	98,80%	1,20%
		\$32.155.986,00		

Nesta tabela pode-se observar a distribuição dos recursos antes mencionados ao longo dos cinco anos, como também a verba não utilizada, a qual é reintegrada ao governo federal em cada início de ano mediante a prestação de contas.

Podemos concluir que as finanças estão sob controle e desde 2018 até 2022 o **IBP** está em luz verde, em suas metas anuais, usando em média, 92% de seus recursos, para o desenvolvimentos dos projetos de pesquisa, sem ficar números vermelhos em seus dados.

Gráfico 13: Custos dos Projetos por Regiões

Area	Centro-Oeste	Nordeste	Norte	Sudeste	Sul	Total
Tecnologia	\$728.766,00	\$1.425.240,00	\$203.818,00	\$2.673.946,00	\$1.050.566,00	\$6.082.336,00
Meio Ambiente	\$206.678,00	\$441.660,00	\$33.074,00	\$1.064.679,00	\$274.775,00	\$2.020.866,00
Biologia	\$480.166,00	\$638.852,00		\$665.719,00	\$87.957,00	\$1.872.694,00
Educação		\$314.769,00	\$3.557,00	\$601.045,00	\$606.797,00	\$1.526.168,00
Saúde	\$161.188,00	\$276.708,00	\$20.302,00	\$432.815,00	\$562.640,00	\$1.453.653,00
Políticas Públicas	\$57.461,00	\$293.530,00	\$6.487,00	\$516.966,00	\$541.718,00	\$1.416.162,00
Inclusão	\$44.085,00	\$227.089,00		\$540.114,00	\$403.009,00	\$1.214.297,00
Engenharia	\$9.590,00	\$353.872,00		\$440.752,00	\$330.265,00	\$1.134.479,00
Energia	\$32.832,00	\$425.997,00	\$182.993,00	\$224.417,00	\$223.661,00	\$1.089.900,00
Agricultura	\$166.455,00	\$239.834,00		\$253.411,00	\$384.786,00	\$1.044.486,00
Total	\$3.672.644,00	\$7.691.905,00	\$1.020.670,00	\$11.558.625,00	\$8.212.142,00	\$32.155.986,00

O gráfico revela os tipos de projetos desenvolvidos nas cinco regiões do Brasil (Centro-Oeste, Nordeste, Norte, Sudeste e Sul) de acordo com o financiamento utilizado. Observa-se que os projetos com maior investimento estão na área de tecnologia, seguido de meio ambiente, biologia, educação, saúde, políticas públicas e inclusão. Esses resultados indicam que um nível significativo de recursos financeiros está sendo destinado a projetos relacionados à tecnologia.

Conclusões

Em virtude que o **IBP** conta com uma verba anual e liquidez financeira, para a aprovação e licitações dos projetos recomendamos:


- ☐ Incentivar os sociólogos do instituto na criação de projetos que produzam políticas públicas planejadas para o desenvolvimento da região norte, que é a região do país esquecida segundo os dados apresentados nos dashboards.
- ☐ Promover projetos de desenvolvimento sustentável, respeitando a biodiversidades e a cultura local, e evitando o desmatamento e a exploração ilegal de recursos naturais.
- ☐ Criar projetos para fortalecer a participação social dos povos indígenas e ribeirinhos, garantidos seus direitos e sua representatividade.
- ☐ Estimular a criação de equipes híbridas de pesquisa, formada por homens e mulheres, com visão de aumentar a participação das mulheres cientistas

nas pesquisas do instituto. Indicador que chamou atenção nos dados apresentados, o qual pode guiar a existência de desigualdades de gênero com relação às mulheres, em termos de horas trabalhadas em relação aos homens.

- ☐ Capacitar a equipe sobre a importância da diversidade de gênero no ambiente de trabalho.
- ☐ Criar políticas de diversidade de gênero, definindo metas, ações e indicadores para aumentar a participação das cientistas mulheres.
- ☐ Dar feedbacks positivos e reconhecimentos públicos para as mulheres que se destacam nos projetos.
- ☐ Oferecer bonificações financeiras ou benefícios extras para as mulheres que atinjam as metas propostas.

Extras

Fluxo do projeto



Autores



John Cardona

Maoly Lara

Nadi Duno

Silvia Ruiz

Desenvolvedor

Analista de dados

Full-Stack

Cientista de dados

Analista de dados

Repositório do GitHub

Dev John Cardona Dev Maoly Lara Dev Nadi Duno Dev Silvia Ruiz

DataCientists

Fictitious data from a database of scientists from the Brazilian Institute of Research. The data provided here are for educational purposes, for a challenge of the bootcamp speed hiring of Toti Diversity.

#Speed Hiring - Data Scientists



Contributors 4

-  nadiduno Nadi Duno
-  MaolyLara MaolyLara
-  ausentes john hernandez
-  Bsilvia20 Silvia Ruiz


Languages

Jupyter Notebook 100.0%


Disponível em: <https://github.com/nadiduno/DataCientists>

Página web do projeto

- ☐ Código em HTML e integração do Dashboard de Power BI




```
index.html - IBP_InterfaseWEB - Visual Studio Code
index.html
<? index.html > <html> <body> <main> <section#equipe> <h2>
You, há 19 horas | 1 author (You)
1 <!DOCTYPE html>
2 <html>
3 <head>
4 <title>Instituto Brasileiro de Pesquisa - IBP</title>
5 <meta charset="UTF-8">
6 <meta name="viewport" content="width=device-width, initial-scale=1.0">
7 <link rel="stylesheet"
8 href="https://maxcdn.bootstrapcdn.com/bootstrap/4.3.1/css/bootstrap.min.css">
9 <link rel="stylesheet" href="https://cdn.jsdelivr.net/npm/font-awesome/5.15.3/css/all.min.css">
10 <link rel="stylesheet" href="style.css">
11 <link rel="img" href="/img/">
12 <script src="script.js"></script>
13
14 </head>
15 <body>
16 <header>
17 <nav class="navbar">
18 <div class="logo">
19 
20 </div>
21 <div>
22 <a class="active" href="#about">Sobre</a>
23 <a href="#proposta-solucao">Proposta de Solução</a>
24 <a href="#planning">Planejamento</a>
25 <a href="#PowerBI">Power BI - IBP</a>
```



```
resultados serão apresentados, recomendações (insights) que puderam ser obtidas com suas análises.
</a></li>
96 </ul>
97 <p>Á POC (Proof of Concept), etapas do projeto mínimo entregáveis, sujeito a
aprovação e validação da Toti, logo da Submissão do Challenge no dia 22-05-2023.</p>
98 </div>
99 </section>
100
101 <section id="PowerBI">
102 <div class="container">
103 <div class="wrapper">
104 <!-- Adicione o iframe com a URL do seu relatório em Power BI -->
105 <iframe title="Analytech" width="100%" height="600"
src="https://app.powerbi.com/view?
r=eyJrIjoimWYxMTVtMTI2OS00NzBmLWI1MGMtOWQ0Nzc2YzZmZnVkiiwidCI6IjE0YmU1ZTFkLTMyMGYtNDg0Ni1iNGIwLTJlNTkzNzc1NmQwZCJ9&pageName=ReportSection25fe764193a13542a9e5" frameborder="0" allowFullScreen="true">
</iframe>
106 <!--<iframe src="https://app.powerbi.com/view?r=xxxxxxxxxxxxxxxx" width="100%"
height="600"></iframe> -->
107 </div>
108 </div>
109 </section>
110
```

❑ Interface Web — Aplicação:



Disponível em: <https://ibp-interfase-web.vercel.app/>